Caderno RAG Experimental

Corpus de teste original e autorizado.

Licenca: CC0 1.0.

Objetivo

Este caderno descreve um MVP local para estudar RAG.

O sistema responde perguntas sobre livros enviados pela pessoa usuaria.

Entrada aceita

O MVP aceita somente arquivos PDF com texto selecionavel.

Documentos digitalizados sem camada textual nao sao suportados.

Origem paginada

Cada trecho preserva o livro e as paginas de origem.

Uma citacao pode indicar uma pagina ou uma faixa de paginas.

Segmentacao

O texto e dividido em chunks de aproximadamente 600 tokens.

Chunks vizinhos usam sobreposicao moderada para preservar o contexto.

Infraestrutura

PostgreSQL guarda o catalogo e o estado dos livros.

Redis executa as filas e Qdrant armazena os vetores.

Estados do livro

Um livro pode estar uploaded, processing, ready ou failed.

Somente livros ready podem responder perguntas.

Recuperacao

A consulta busca os seis chunks mais proximos por padrao.

Um filtro por livro restringe a busca aos livros selecionados e prontos.

Resposta fundamentada

A resposta usa somente os chunks recuperados.

Cada fonte mostra titulo, paginas e um excerto de apoio.

Contexto insuficiente

Sem evidencia recuperada ou fonte valida, insufficientContext e verdadeiro.

Nessa situacao o sistema nao inventa uma resposta.

Privacidade

PDFs enviados ficam em armazenamento local privado.

O diretorio de uploads nao deve ser servido publicamente.

Limite do MVP

OCR, EPUB, DOCX e memoria conversacional estao fora do escopo inicial.

O corpus e destinado apenas a testes automatizados.